信息组织与检索

第5讲：索引压缩

主讲人：张蓉

华东师范大学 数据科学与工程学院

提纲

- 上一讲回顾
- 压缩
- 词项统计量
- 词典压缩
- 倒排记录表压缩

提纲

- 上一讲回顾
- 压缩
- 词项统计量
- 词典压缩
- 倒排记录表压缩

基于块的排序索引构建算法BSBI

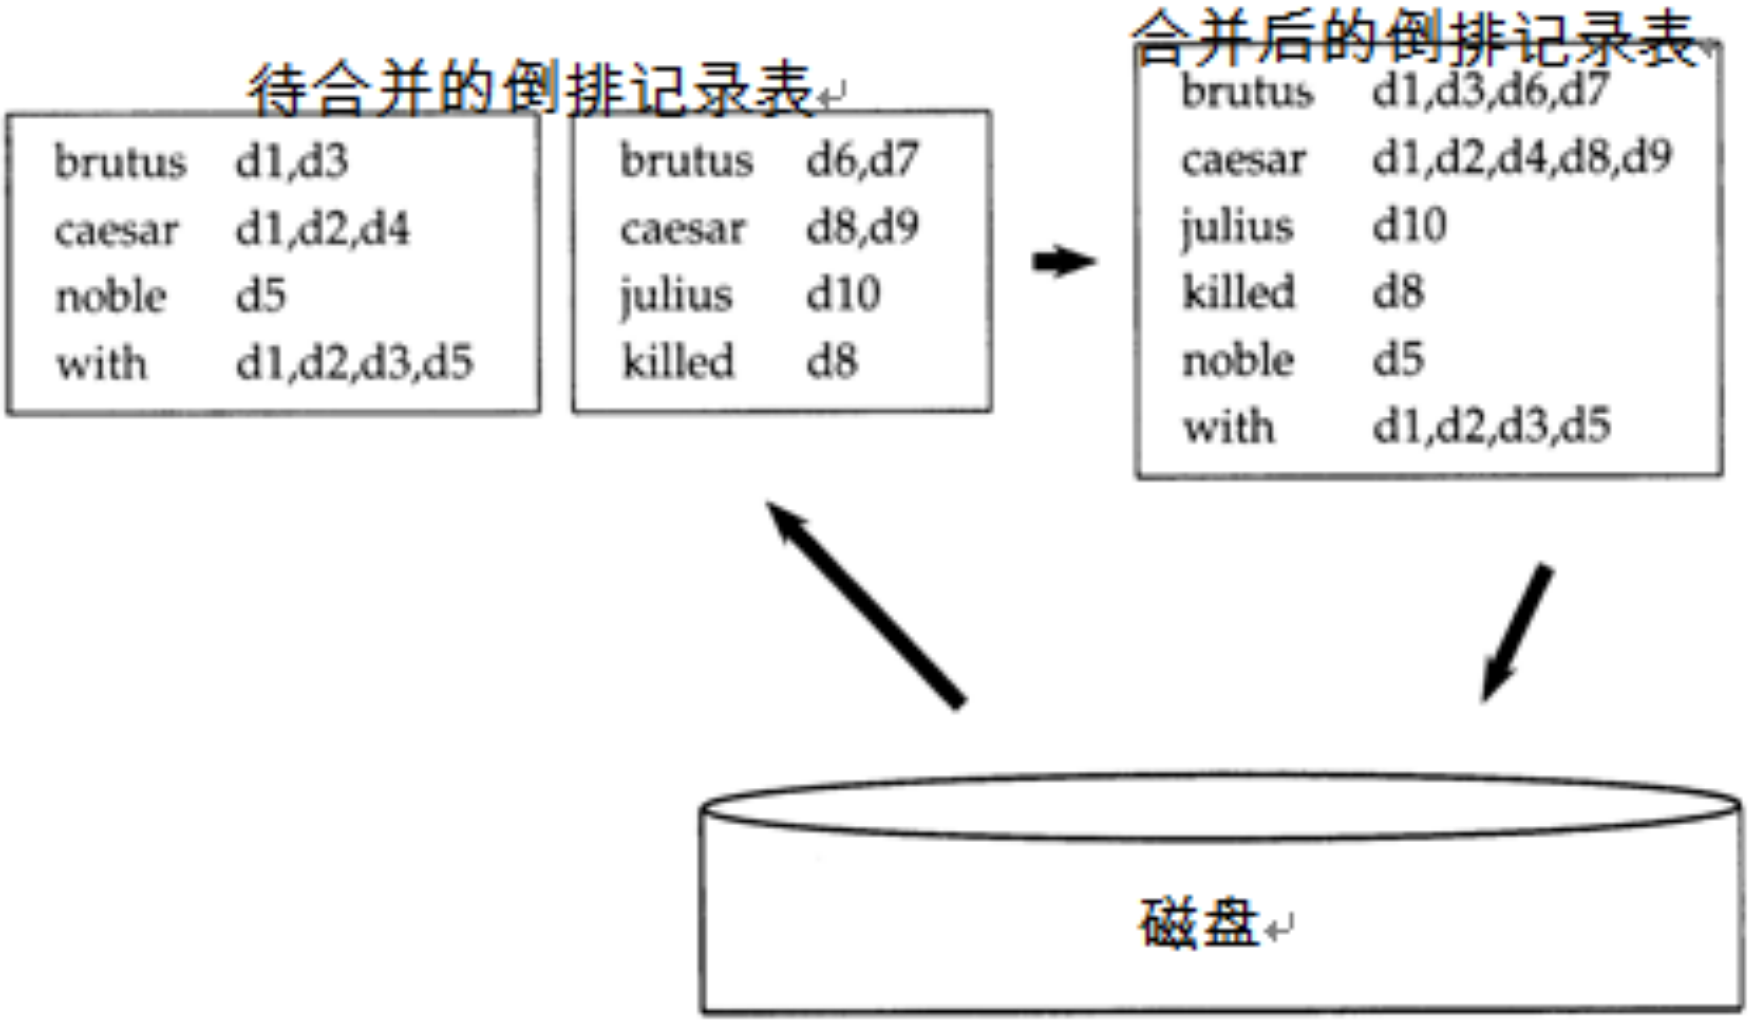

内存式单遍扫描索引构建算法SPIMI

- **关键思想 1:** 对每个块都产生一个独立的词典 – 不需要在块之间进行term-termID的映射
- **关键思想2:** 对倒排记录表不排序，按照他们出现的先后顺序排列
- 基础上述思想可以对每个块生成一个完整的倒排索引
- 这些独立的索引最后合并一个大索引

基于MapReduce的索引构建

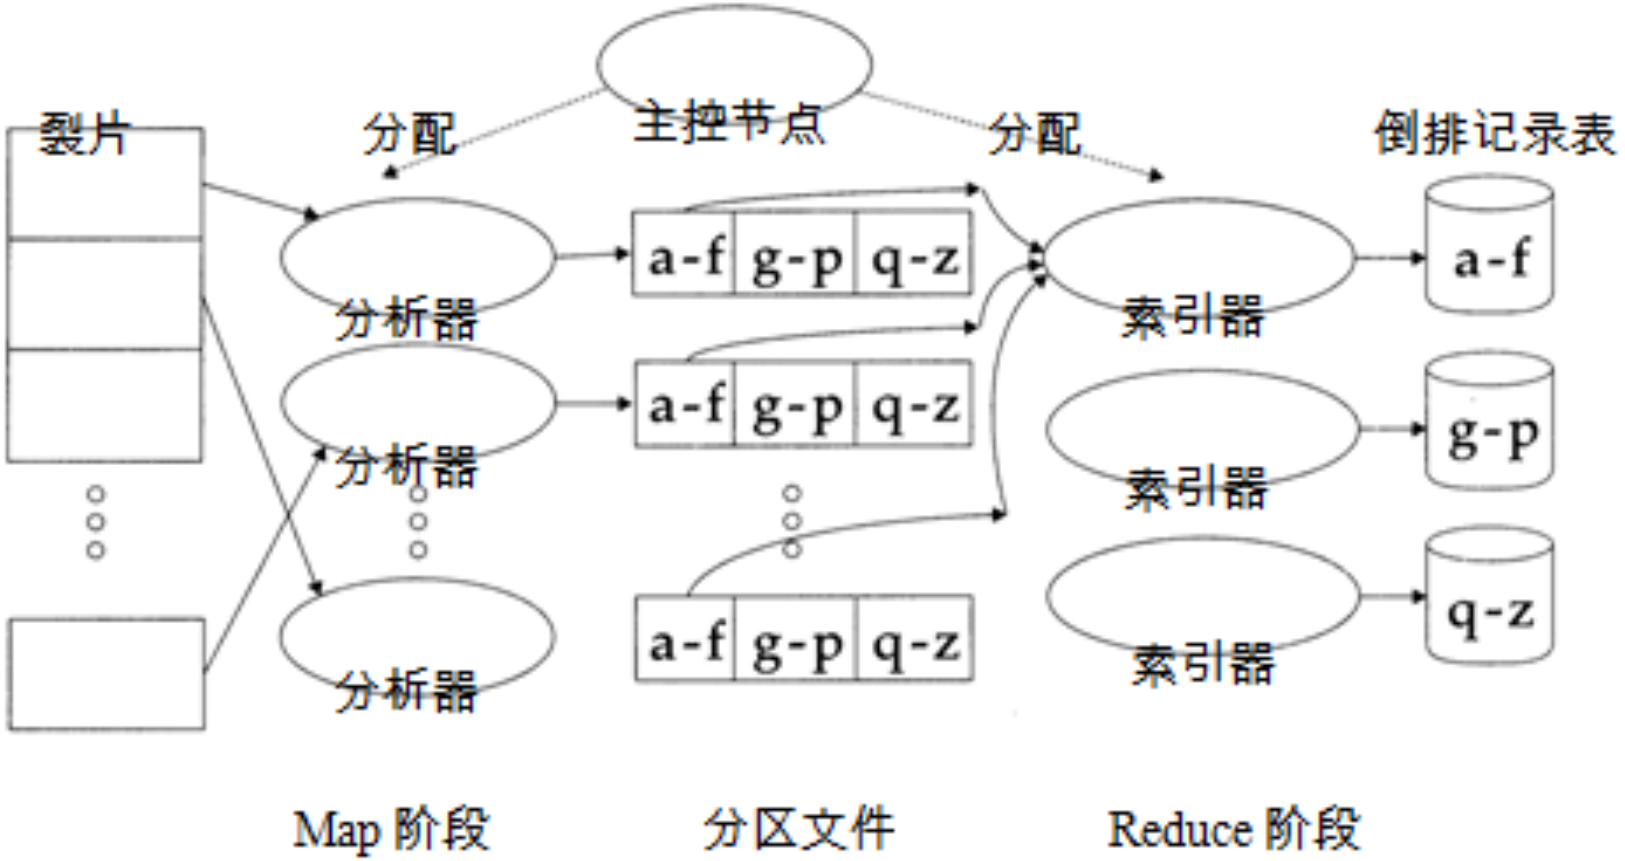

动态索引构建：最简单的方法

- 在磁盘上维护一个大的主索引(Main index)
- 新文档放入内存中较小的辅助索引（Auxiliary index）中
- 同时搜索两个索引，然后合并结果
- 定期将辅助索引合并到主索引中

本讲内容

- 信息检索中进行压缩的动机(Why)
- 倒排索引中词典部分如何压缩？(How)
- 倒排索引中倒排记录表部分如何压缩？(How)
  - 词项统计量: 词项在整个文档集中如何分布？

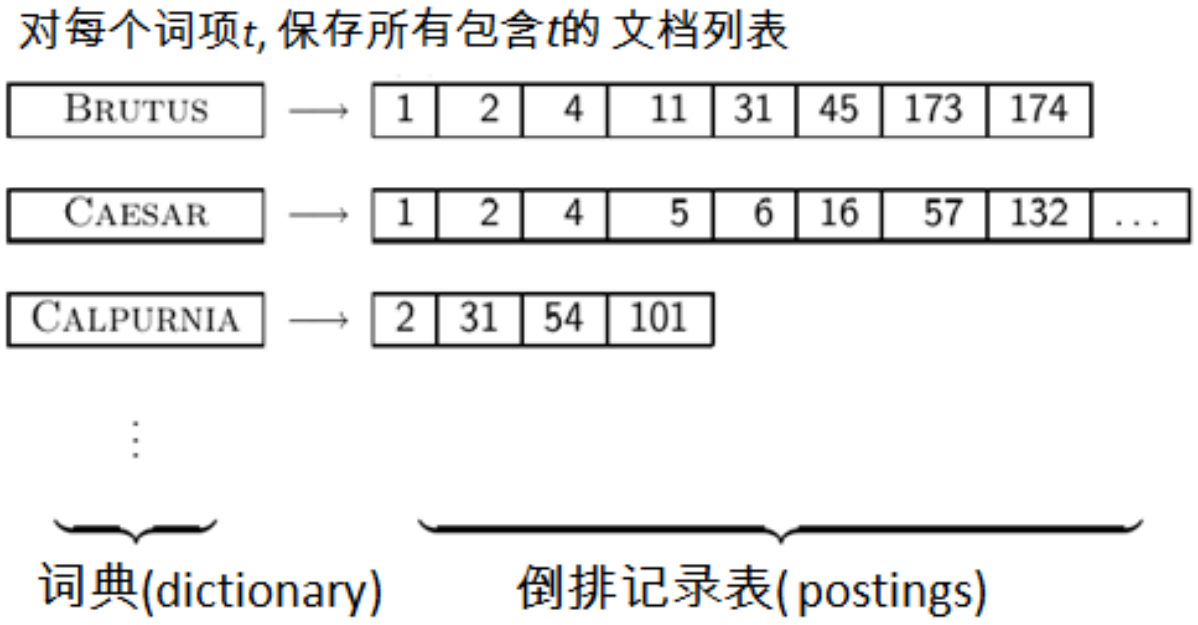

提纲

- 上一讲回顾
- 压缩
- 词项统计量
- 词典压缩
- 倒排记录表压缩

什么是压缩?

- 将长编码串用短编码串来代替
  - 1111111111111111➔ 18个1

winrar

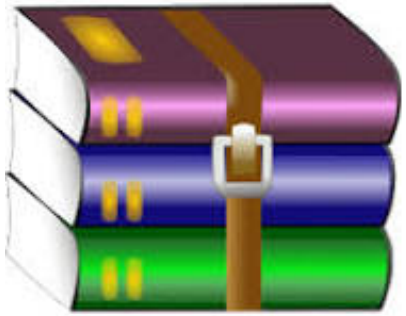

为什么要压缩?(通常来说)

- 减少磁盘空间 (节省开销)
- 增加内存存储内容 (加快速度)
- 加快从磁盘到内存的数据传输速度 (同样加快速度)
  - [读压缩数据到内存+在内存中解压]比直接读入未压缩数据要快很多
  - 前提: 解压速度很快
- 本讲我们介绍的解压算法的速度都很快

为什么在IR中需要压缩?

- 首先，需要考虑词典的存储空间
  - ✓词典压缩的主要动机: 使之能够尽量放入内存中
- 其次，对于倒排记录表而言
  - ✓动机: 减少磁盘存储空间，减少从磁盘读入内存的时间
  - ✓注意: 大型搜索引擎将相当比例的倒排记录表都放入内存
- 接下来，将介绍词典压缩和倒排记录表压缩的多种机制

有损(Lossy)vs.无损(Lossless)压缩

- **有损压缩**: 丢弃一些信息，例子?
- 前面讲到的很多常用的预处理步骤可以看成是有损压缩:
  - 统一小写,去除停用词, Porter词干还原, 去掉数字

- **无损压缩**: 所有信息都保留，例子?
  - 索引压缩中通常都使用无损压缩

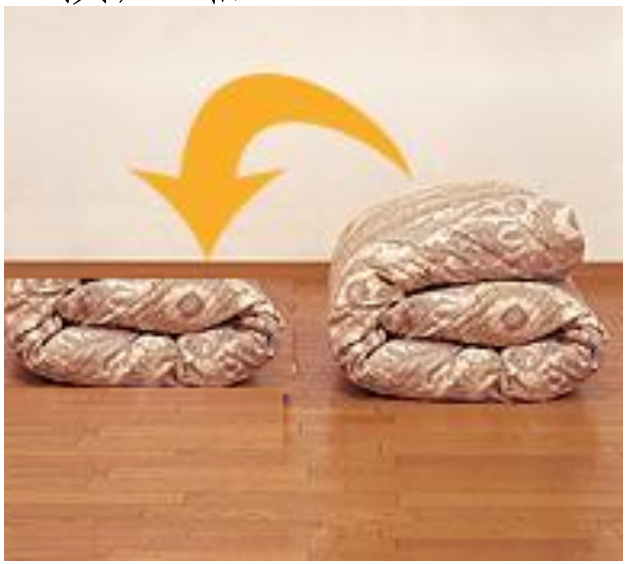

提纲

- 上一讲回顾
- 压缩
- 词项统计量
- 词典压缩
- 倒排记录表压缩

词典压缩和倒排记录表压缩

- 词典压缩中词典的大小即词汇表的大小是关键
  - ✓能否预测词典的大小?
- 倒排记录表压缩中词项的分布情况是关键
  - ✓能否对词项的分布进行估计?
- 引入词项统计量对上述进行估计，引出两个经验法则

对文档集建模： Reuters RCV1

N	文档数目	800,000
L	每篇文档的词条数目	200
M	词项数目(= 词类数目)	400,000
	每个词条的字节数 (含空格和标点)	6
	每个词条的字节数 (不含空格和标点)	4.5
	每个词项的字节数	7.5
T	无位置信息索引中的倒排记录数目	100,000,000

预处理的效果(有损)

	不同词项			无位置信息倒排记录			词　　条①		
	数目	Δ%	T%	数目	Δ%	T%	数目	Δ%	T%
未过滤	484 494			109 971 179			197 879 290		
无数字	473 723	–2	–2	100 680 242	–8	–8	179 158 204	–9	–9
大小写转换	391 523	–17	–19	96 969 056	–3	–12	179 158 204	–0	–9
30个停用词	391 493	–0	–19	83 390 443	–14	–24	121 857 825	–31	–38
150个停用词	391 373	–0	–19	67 001 847	–30	–39	94 516 599	–47	–52
词干还原	322 383	–17	–33	63 812 300	–4	–42	94 516 599	–0	–52

第一个问题：词汇表有多大
(即词项数目)?

- 即有多少不同的单词数目?
  - ✓首先，能否假设这个数目存在一个上界?
  - ✓不能：对于长度为20的单词，有大约$70^{20} \approx 10^{37}$种可能的单词
- 实际上，词汇表大小会随着文档集的大小增长而增长!
- Heaps定律: $M = kT^b$
  - M 是词汇表大小, T是文档集的大小(所有词条的个数，即所有文档大小之和)
  - 参数k和b的一个经典取值是: $30 \leqslant k \leqslant 100$ 及 $b \approx 0.5$.
- Heaps定律在对数空间下是线性的
  - ✓这也是在对数空间下两者之间最简单的关系
  - ✓经验规律

Reuters RCV1上的Heaps定律

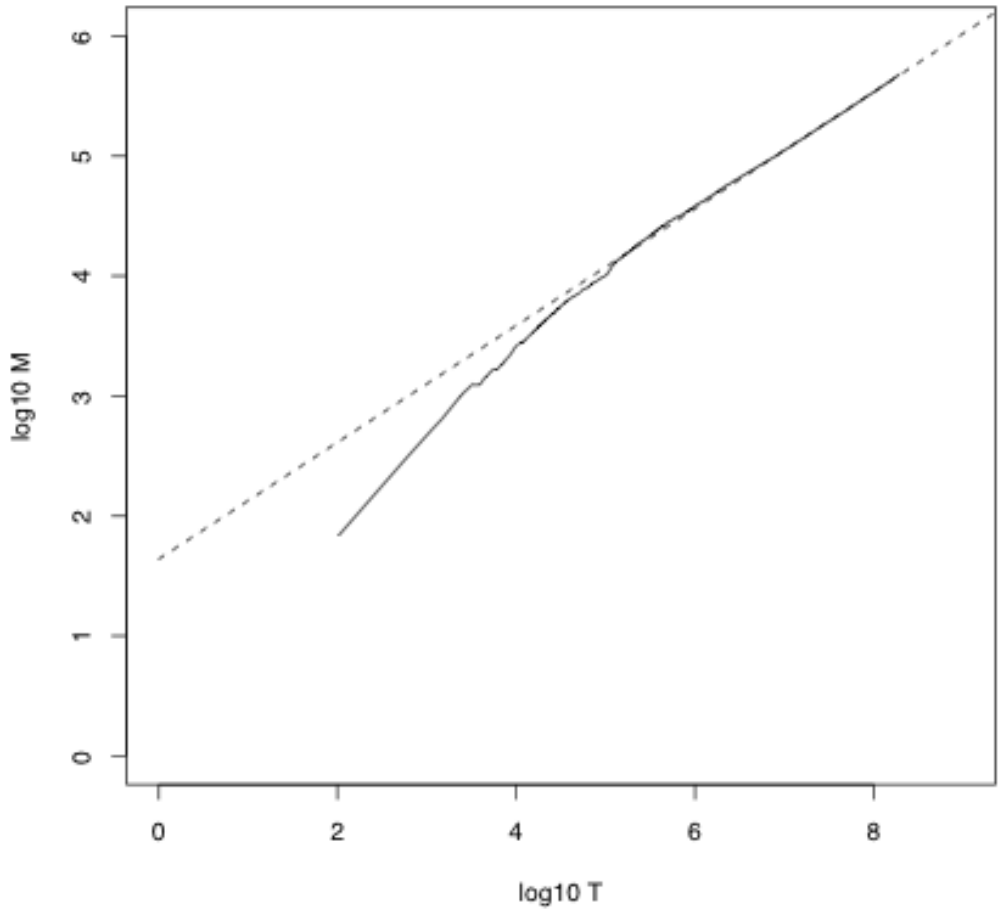

- 词汇表大小M是文档集规模T的一个函数
- 图中通过最小二乘法拟合出的直线方程为：

$$\log_{10} M = 0.49 * \log_{10} T + 1.64$$

- 于是有：

$$M = 10^{1.64} T^{0.49}$$

$$k = 10^{1.64} \approx 44$$

$$b = 0.49$$

拟合 vs. 真实

- 例子: 对于前1,000,020个词条， 根据Heaps定律预计将有38,323个词项:

$$44 \times 1{,}000{,}020^{0.49} \approx 38{,}323$$

- 实际的词项数目为38,365，和预测值非常接近
- 经验上的观察结果表明，一般情况下拟合度还是非常高的

第二个问题：词项的分布如何？Zipf定律

- Heaps定律告诉我们随着文档集规模的增长词项的增长情况
- 但是我们还需要知道在文档集中有多少高频词项 vs. 低频词项。
- 在自然语言中，有一些极高频词项，有大量极低频的罕见词项 a/an/the, 的了地 我
- Zipf定律: 第i常见的词项的频率cf_i和$1/i$成正比

$$cf_i \propto \frac{1}{i}$$

  - cf_i是文档集频率(collection frequency): 词项t_i在所有文档中出现的次数(不是出现该词项的文档数目df)

21

Zipf定律

- Zipf定律: 第i常见的词项的频率cf_i和$1/i$成正比

$$cf_i \propto \frac{1}{i}$$

cf_i是文档频率(collection frequency): 词项t_i在所有文档中出现的次数(不是出现该词项的文档数目df).

- 于是，如果最常见的词项(*the*)出现cf_1次，那么第二常见的词项(*of*)出现次数为 $cf_2 = \frac{1}{2}cf_1$ ...
- ... 第三常见的词项(*and*)出现次数为 $cf_3 = \frac{1}{3}cf_1$
- 另一种表示方式: $cf_i = c*i^k$ 或 $\log cf_i = \log c + k \log i$ $(k = -1)$
- 幂定律(power law)的一个实例
- 生活中的zipf定律
  - 旅游城市的游客访问数量

22

生活中的zipf定律

- 80%的财富集中在20%的人手中
- 80%的用户只使用20%的功能
- 20%的用户贡献了80%的访问量
- 完美的二八定律

生活中的zipf定律

- 网店
  - 网店相当于**用极小的成本，便换来几乎无限长的货架**
  - 可以同时包括大热门以及几乎无人问津的众多冷门

- 能否想几个例子?

Reuters RCV1上Zipf定律的体现

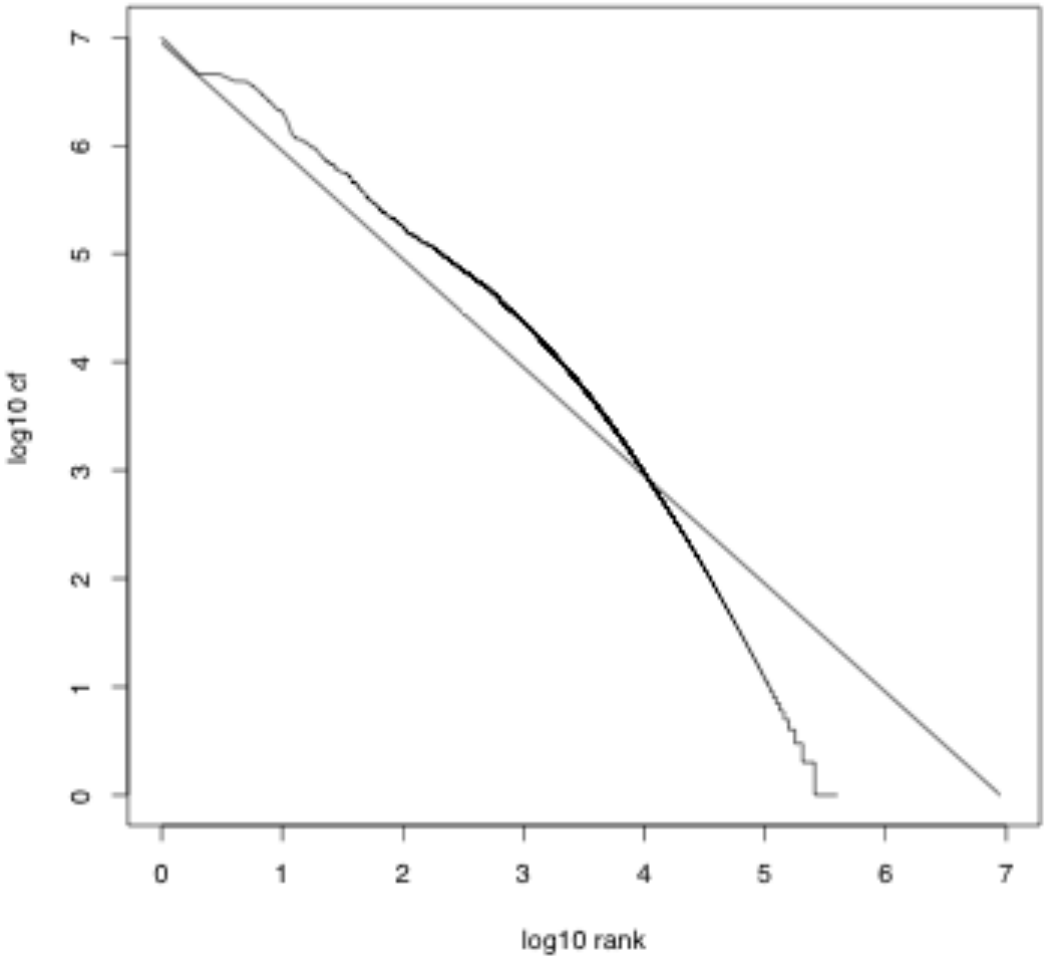

拟合度不是非常高，但是最重要的是如下关键性发现：高频词项很少，低频罕见词项很多

25

提纲

- 上一讲回顾
- 压缩
- 词项统计量
- 词典压缩
- 倒排记录表压缩

词典压缩

- 相对于倒排记录表，词项较小
- 但是我们想将词典放入内存
- 另外，满足一些特定领域特定应用的需要，如手机、机载计算机上的应用或要求快速启动等需求

- 因此，压缩词典相当重要

27

回顾: 定长数组方式下的词典存储

词项	文档频率	指向倒排记录表的指针
a	656 265	→
aachen	65	→
…	…	…
zulu	221	→

空间需求: 20 字节 4 字节 4 字节

对Reuters RCV1语料: (20+4+4)*400,000 = 11.2 MB

28

定长方式的不足

- 大量存储空间被浪费
  - 即使是长度为1的词项，我们也分配20个字节
  - a an
- 不能处理长度大于20字节的词项，如HYDROCHLOROFLUOROCARBONS 和 SUPERCALIFRAGILISTICEXPIALIDOCIOUS
- 而英语中每个词项的平均长度为8个字符
- 能否对每个词项平均只使用8个字节来存储? 现场提问

将整部词典看成单一字符串(Dictionary as a string)

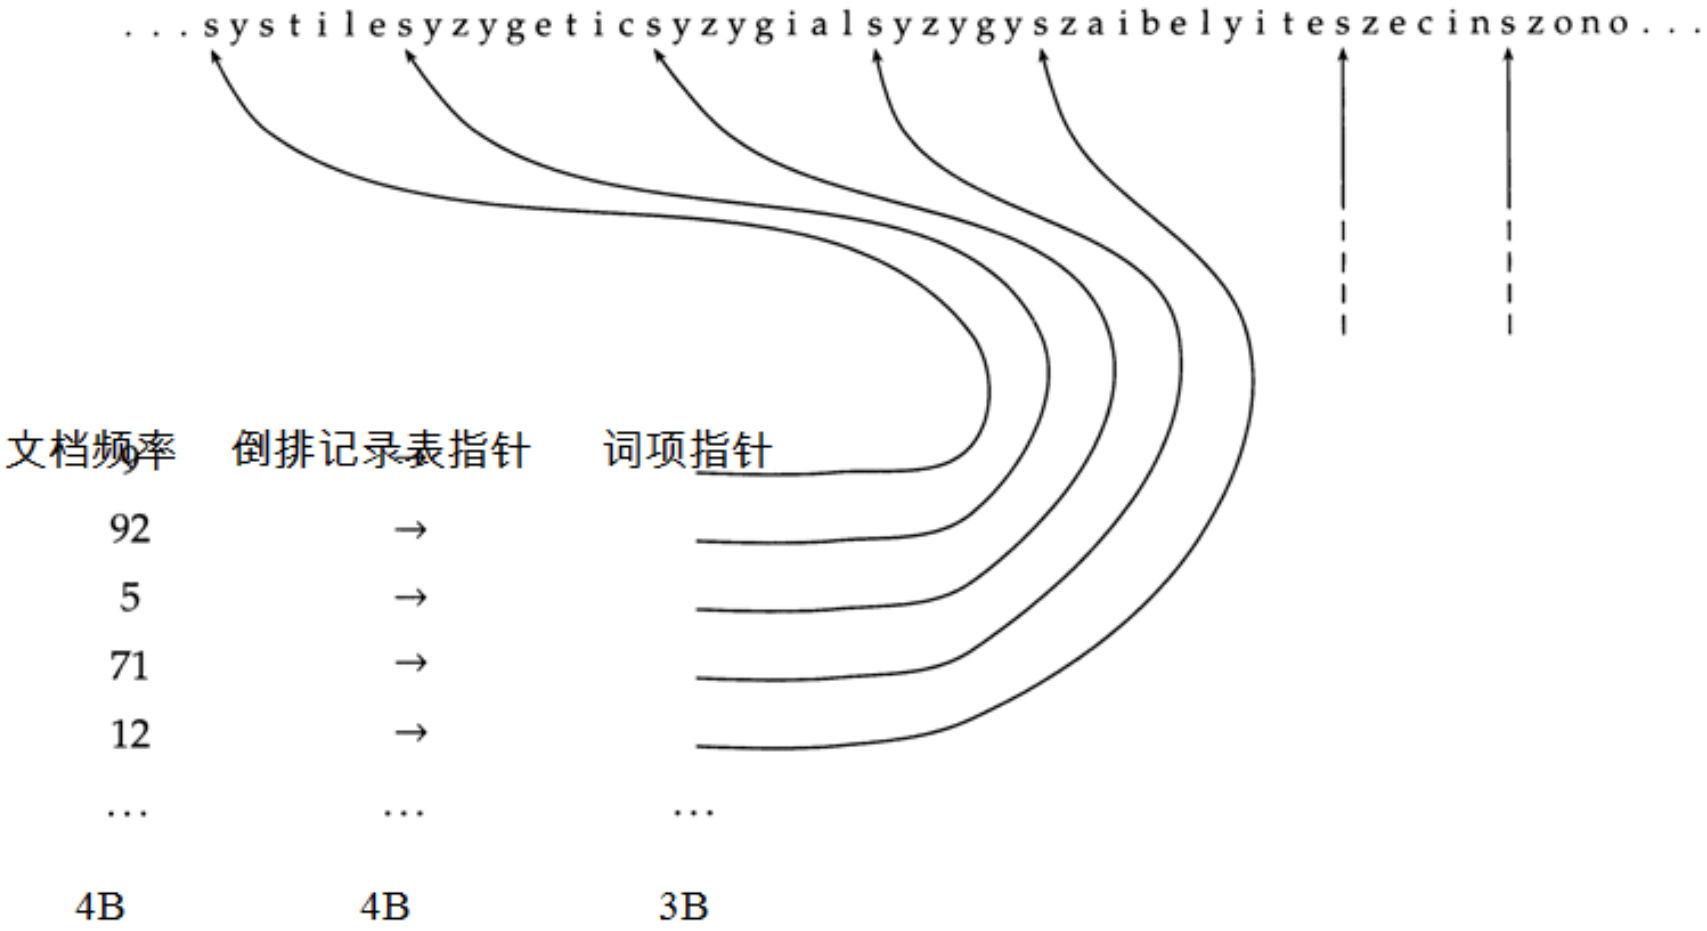

30

单一字符串方式下的空间消耗

- 每个词项的词项频率需要4个字节
- 每个词项指向倒排记录表的指针需要4个字节
- 每个词项平均需要8个字节
- 指向字符串的指针需要3个字节 (8*400000个位置需要log2（8 * 400000） < 24 位来表示)
- 空间消耗: 400,000 × (4 +4 +3 + 8) = 7.6MB （而定长数组方式需要11.2MB)

31

单一字符串方式下按块存储

32

按块存储下的空间消耗

- 如果不按块存储，则每4个词项指针将占据空间4 × 3=12B
- 现在按块存储，假设块大小k=4，此时每4个词项只需要保留1个词项指针，但是同时需要增加4个字节来表示每个词项的长度，此时每4个词项需要3+4=7B
- 因此，每4个词项将节省12-7=5B
- 于是，整个词典空间将节省40,000/4*5B=0.5MB
- 最终的词典空间将从7.6MB压缩至7.1MB

不采用块存储方式下的词项查找

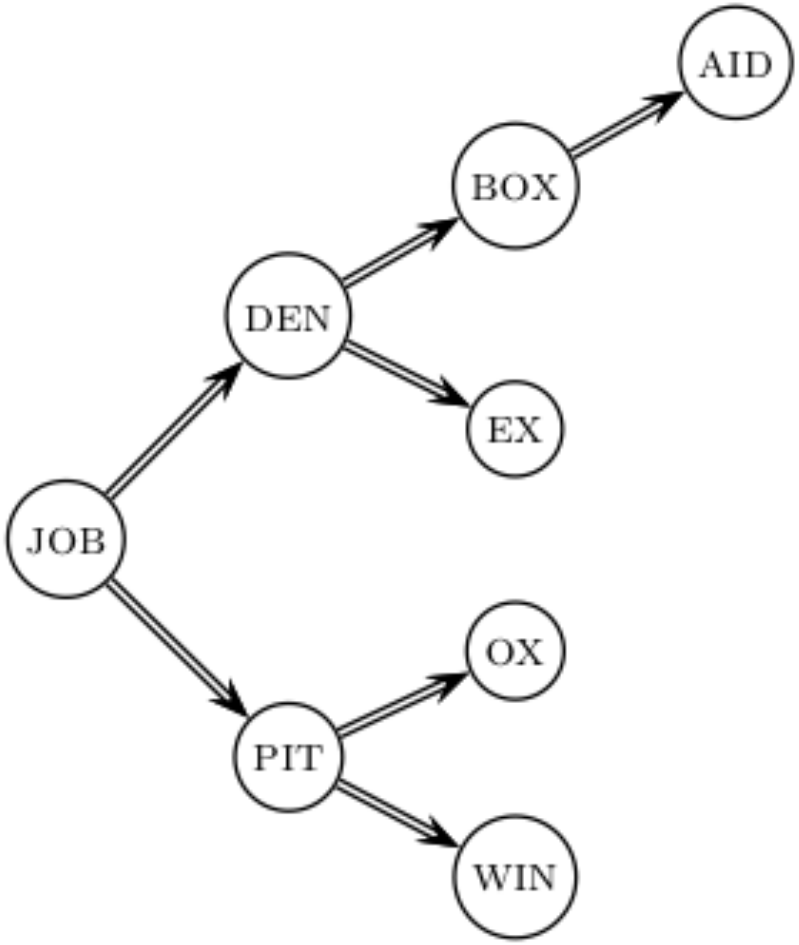

34

采用块存储方式下的词项查找: 稍慢

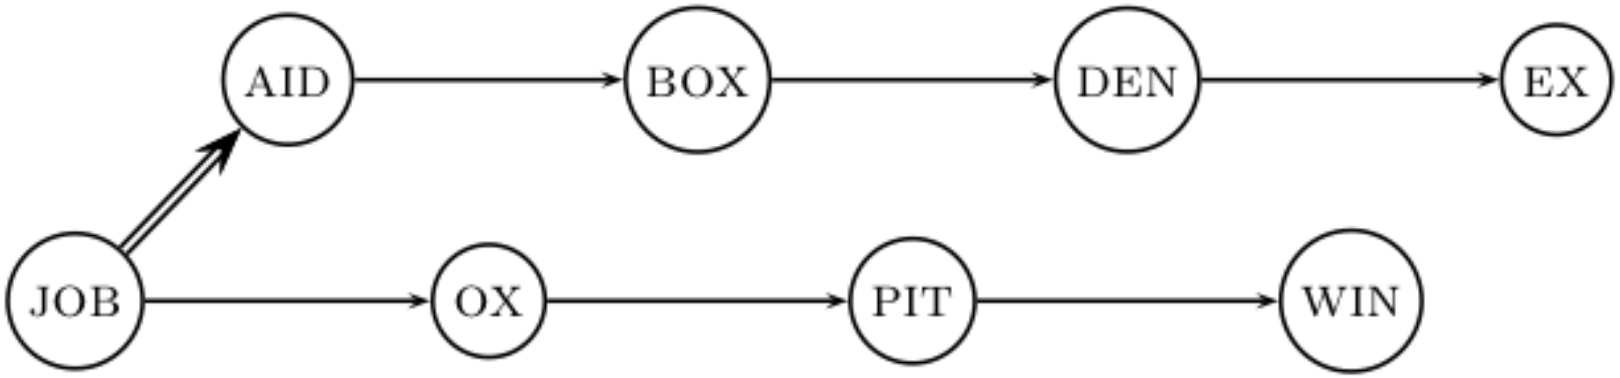

35

前端编码(Front coding)

- 每个块当中 (k = 4)，会有公共前缀 . . .

8automata8automate9automatic10automation

⇓

- . . . 可以采用前端编码方式继续压缩
- 8automat∗a1⋄e2⋄ic3⋄ion

1/2/3表示什么？

表示词项长度，比如1表示 e只有一个字符

Reuters RCV1词典压缩情况总表

数据结构	压缩后的空间大小（单位：MB）
词典，定长数组	11.2
词典，长字符串+词项指针	7.6
词典，按块存储，k=4	7.1
词典，按块存储+前端编码	5.9

37

提纲

- 上一讲回顾
- 压缩
- 词项统计量
- 词典压缩
- 倒排记录表压缩

倒排记录表压缩

- 倒排记录表空间远大于词典，至少10倍以上
- 压缩关键：对每条倒排记录进行压缩
- 目前每条倒排记录表中存放的是docID.
- 对于Reuters RCV1(800,000篇文档), 当每个docID可以采用4字节（即32位）整数来表示
- 当然，我们也可以采用$\log_2 800{,}000 \approx 19.6 < 20$ 位来表示每个docID.
- 我们的压缩目标是： 压缩后每个docID用到的位数远小于20比特

怎么做？

39

关键思想:
存储docID间隔而不是docID本身

- 每个倒排记录表中的docID是从低到高排序
  - 例子: COMPUTER: 283154, 283159, 283202, . . .
- 存储间隔能够降低开销： 283159-283154=5, 283202-283154=43
- 于是可以顺序存储间隔(第一个不是间隔) : COMPUTER: 283154, 5, 43, . . .
- 高频词项的间隔较小
- 因此，可以对这些间隔采用小于20比特的存储方式

40

对间隔编码

	编码对象	倒排记录表					
the	文档ID	…	283 042	283 043	283 044	283 045	…
	文档ID间距			1	1	2	…
computer	文档ID	…	283 047	283 154	283 159	283 202	…
	文档ID间距			107	5	43	…
arachnocentric	文档ID	252 000	500 100				
	文档ID间距	252 000	248 100				

存在什么问题?

罕见词的处理和常见词，间隔大小差别太大

41

变长编码

- 目标:
  - 对于 ARACHNOCENTRIC 及其他罕见词项, 对每个间隔仍然使用20比特
  - 对于THE及其他高频词项，每个间隔仅仅使用很少的比特位来编码

- 为了实现上述目标，需要设计一个变长编码(variable length encoding)
- 可变长编码对于小间隔采用短编码而对于长间隔采用长编码

42

可变字节(VB)码

- 被很多商用/研究系统所采用
- 设定一个专用位 (高位) *c*作为延续位(continuation bit)
- 如果间隔表示少于7比特，那么*c*置 1，将间隔编入一个字节的后7位中
- 否则：将低7位放入当前字节中，并将*c*置 0，剩下的位数采用同样的方法进行处理，最后一个字节的*c*置1（表示结束）

43

VB 编码的例子

文档ID	824	829	215 406
间距		5	214 577
VB编码	00000110 10111000	10000101	00001101 00001100 10110001

44

VB 编码算法

```
VBEncodeNumber(n)
1  bytes ← ⟨⟩
2  while true
3  do Prepend(bytes, n mod 128)
4     if n < 128
5        then Break
6     n ← n div 128
7  bytes[Length(bytes)] += 128
8  return bytes
```

```
VBEncode(numbers)
1  bytestream ← ⟨⟩
2  for each n ∈ numbers
3  do bytes ← VBEncodeNumber(n)
4     bytestream ← Extend(bytestream, bytes)
5  return bytestream
```


45

VB编码的解码算法

```
VBDecode(bytestream)
 1  numbers ← ⟨⟩
 2  n ← 0
 3  for i ← 1 to Length(bytestream)
 4  do if bytestream[i] < 128
 5        then n ← 128 × n + bytestream[i]
 6        else n ← 128 × n + (bytestream[i] − 128)
 7             Append(numbers, n)
 8             n ← 0
 9  return numbers
```


46

其它编码

- 除字节外，还可以采用不同的对齐单位：比如32位(word)、16位及4位(nibble)等等
- 如果有很多很小的间隔，那么采用可变字节码会浪费很多空间，而此时采用4位为单位将会节省空间
- 最近一些工作采用了32位的方式

47

Reuters RCV1索引压缩总表

数据结构	压缩后的空间大小（单位：MB）
词典，定长数组	11.2
词典，长字符串+词项指针	7.6
词典，按块存储，k=4	7.1
词典，按块存储+前端编码	5.9
文档集（文本、XML标签等）	3 600.0
文档集（文本）	960.0
词项关联矩阵	40 000.0
倒排记录表，未压缩（32位字）	400.0
倒排记录表，未压缩（20位）	250.0
倒排记录表，可变字节码	116.0
倒排记录表，γ编码	101.0

48

总结

- 现在我们可以构建一个空间上非常节省的支持高效布尔检索的索引
- 大小仅为文档集中文本量的10-15%
- 然而，这里我们没有考虑词项的出现位置和频率信息
- 因此，实际当中并不能达到如此高的压缩比

49

本讲小结

- 信息检索中进行压缩的动机
- 倒排索引中词典部分如何压缩？长字符串方法及改进
- 倒排索引中倒排记录表部分如何压缩？可变字节码、γ编码
- 词项统计量: 词项在整个文档集中如何分布？ 两个定律

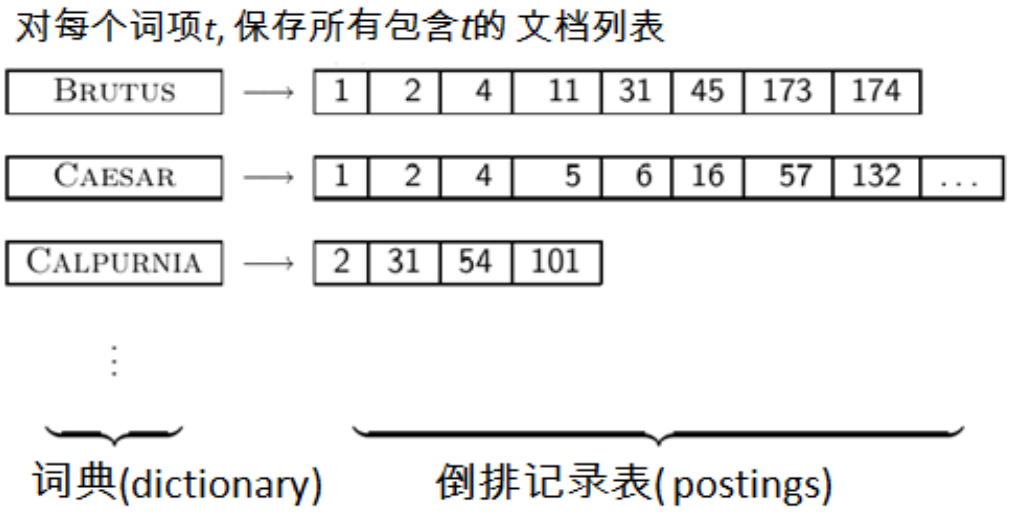

课堂练习：词典压缩

- 假设有下列词项
  - the
  - these
  - thess
  - that
  - able
  - ace
- 计算各个步骤的空间消耗
  - 从开始消耗到最后一步的消耗变化